

GUIA DE REFERÊNCIA ARQUITETURA DE DADOS - DATALAKE CLOUD

Banco Santander Totta

ÍNDICE

1	Introdução	3
2	Definições	3
3	Novas Ingestas	4
4	Novos Modelos de Dados	8
5	Considerações finais	12

1 INTRODUÇÃO

O presente documento apresenta os princípios que têm de ser seguidos de forma a cumprir com os standards do Banco Santander relativamente às boas práticas de Arquitetura de Dados para iniciativas de criação ou consumo de repositórios de dados em datalake na plataforma cloud Azure (Bahia)

2 DEFINIÇÕES

O Datalake Cloud deverá ser o local privilegiado para a construção, exploração e disponibilização de novos modelos de dados bem como elaboração de reportes internos e externos tanto para gestão como para reguladores, de acordo com o plano estratégico de dados.

O Datalake encontra-se organizado conforme o esquema abaixo:




Figura 1 - Organização do Datalake Cloud

Data-zones: A existência de diferentes data-zones para disponibilização de informação permite que os dados estejam organizados de acordo com o seu grau de maturidade e os objetivos de disponibilização e consumo dos mesmos

Proveniência dos Dados: existem duas fontes de proveniência dos dados, dados com origem noutros sistemas (designados por ingestas) e dados criados/transformados no Datalake.

Localização dos dados: As ingestas ficaram nas zonas *raw* e *curated*, são carregados via framework de ingestão (Pikota) e arrumados de acordo com a aplicação origem. Serão consumidos exclusivamente a partir da zona *curated*.

Os dados criados/transformados ficarão na zona “common”, caso se trate de informação referente a modelos comuns de dados, ou na zona “business” para novos dados informacionais e aplicativos que resultem da alteração ou amplificação de dados das zonas *curated*, *common* e/ou *business*

O acesso de informação das aplicações na área “business” deve ser preferencialmente efetuado a partir da zona “common”.

Existem ainda duas zonas adicionais (*workbench* e *operation*) que se detalham na figura 2.



Figura 2 - Detalhe das data-zones

3 NOVAS INGESTAS

3.1 Análise da necessidade

Quando um utilizador identifica a necessidade de ter em Datalake informação proveniente de outros sistemas, deverá sempre que possível verificara se a mesma já existe. Caso a informação já exista, deve ser verificada a completitude desses dados bem como se a

profundidade histórica é suficiente para a nova necessidade e se as políticas de house-keeping (regras de expurgo) estão também alinhadas com as necessidades futuras.

3.2 Pedido de autorização

Caso se verifique que a informação não existe, deve então ser solicitada a informação ao Datalake Working Group (DWG) de acordo com o procedimento em vigor.

A solicitação de uma nova ingesta ao DWG é suportada pela apresentação de uma ficha que deverá estar corretamente preenchida, pelo menos com os campos obrigatórios.




Figura 3 - Fluxo de pedidos de ingesta

3.3 Identificação em APM

A aplicação de origem dos dados tem de estar registada na Application Portfolio Management (APM) sendo necessário o código APM, com o qual será feito o relacionamento com a Base de Dados (BD) onde a ingesta ficará materializada. Sem esta informação não será possível fazer o pedido de ingesta ao DWG.

3.4 Origem dos dados

Relativamente à origem dos dados para exploração e novos desenvolvimentos, estes deverão provir de um sistema de forma automática o mais próximo possível da origem dos mesmos.

As ingestas automáticas têm exclusivamente de ser configuradas utilizando a Pikota Tool.

Caso a informação requerida não exista em nenhum sistema, a ingesta terá de ser configurada de forma a ser executada a partir do front-end para ingestas manuais, estando vedado aos utilizadores qualquer outra forma de carregamento de informação, como por exemplo ingestas configuradas a partir de pastas partilhadas.

Em casos pontuais, na fase de desenvolvimento, as equipas técnicas (operação) poderão realizar ingestas pontuais de forma provisória

3.5 Designação de Bases de Dados

A designação da BD seguirá a nomenclatura `raw/curated_<source origin>_<source system>_<app>` e é responsabilidade do WKG indicar o nome e a aprovação para criação da mesma, no âmbito da sua atividade.

3.6 Designação de Tabelas

O nome das tabelas deverá ser exatamente igual à designação da tabela no sistema origem e deverá ter uma descrição funcional completa e perceptível para qualquer potencial consumidor

Para ingestas provenientes do mainframe (Sintra/Partenon), terão de ser utilizados unloads das tabelas pretendidas e dependendo do tamanho, os ficheiros terão de ser compactados para .Zip. Caso não existam unloads, ou seja, necessário assegurar a compactação, deverá ser pedida estimativa e plano pelo solicitante junto da equipa responsável da aplicação, ficando a possibilidade de operacionalização da ingesta dependente destes desenvolvimentos. É necessário também obter o copybook correto da tabela de forma que a ingesta seja operacionalizada sem erros.

Sobre as tabelas com origem em unloads deve observar-se o seguinte:

- As ingestas de tabelas a partir de unloads deverão garantir a completitude dos dados da tabela origem, quer em número de registos como campos, garantindo o nome igual a tabela origem;

Caso a ingesta seja de um ficheiro gerado em mainframe cujos dados não estão materializados em tabela (por exemplo, geyrn000), deve observar-se o seguinte:

- Designação: deverá seguir a seguinte regra `<código aplicação>_<copybook>_<descrição>` respeitando o máximo de 32 caracteres;

- Ficheiros gerados que sejam apenas cruzamento de tabelas não deverão ser ingestados, devendo proceder-se a ingesta das tabelas origem.

Para todas as ingestas deve ser garantida a posição de final de dia.

3.7 Designações de Campos

Relativamente aos nomes dos campos, estes deverão ser exatamente iguais ao nome dos campos na origem, devendo cada campo ter o descritivo do seu significado de forma perceptível para qualquer potencial consumidor.

Para ingestas com origem em unloads de ficheiros de mainframe, os nomes dos campos deverão ser iguais aos nomes dos campos das tabelas origem e não devem incluir o prefixo do copybook

3.8 Periodicidade e Histórico

No pedido de ingesta deverá ser indicado os requisitos relativos a periodicidade e histórico.

A periodicidade da ingesta deverá estar alinhada o mais possível com periodicidade mínima da fonte, garantindo uma fotografia de fecho do dia. São sempre preferidas ingestas diárias durante um período necessário em função dos casos de uso e guardadas posições de fim de mês até histórico máximo. Caso a ingesta seja diária, deve ser analisado se as ingestas deverão ser efetuadas em dias não-úteis.

As ingestas devem idealmente depender de uma condição de job, em preferência da indicação de condição horária.

Relativamente à tipologia de ingesta, para tabelas de posições deve ser privilegiada a tipologia de ingesta Full e para ingestas de tabelas de fluxos (por exemplo, tabelas de movimentos) deve ser privilegiada o tipo de ingesta incremental, tendo que ser indicada a query para permitir identificar o incremento.

Sempre que necessário devem ser definidas as regras de housekeeping, sendo necessário definir o período de histórico requerido, devendo manter-se o maior histórico legalmente possível, observando o seguinte default:

- Tabelas de posições: 13 meses de posições diárias e 10 anos de posições de fim-de mês;
- Tabelas de Fluxos: 10 anos.

3.9 Controlos

A área solicitante deve indicar, caso entenda necessário, os tipos de controlos a aplicar:

- Controlos forenses sobre qualidade de dados (realizados sobre a informação após a mesma já se encontrar carregada em cloud);
- Controlos sobre ingestas (por exemplo, nº de registos esperado).

Em caso de dúvida sobre necessidade ou definição dos controlos poderá ser contactada a área de CDO.

4 NOVOS MODELOS DE DADOS

4.1 Business

No desenvolvimento de novas iniciativas e novos modelos para exploração e consumo de dados, será definida uma BD na zona “Business”.

4.1.1 *Registo em APM*

Tratando-se de uma nova aplicação, a mesma tem de estar registada no Application Portfolio Management (APM) sendo necessário o código APM, com o qual será feito o relacionamento com a Base de Dados (BD) onde serão criados e guardados os dados. Sem esta informação não será possível a aprovação para criação da Base de Dado.

4.1.2 *Apresentação ao Datalake Working Group*

Os novos desenvolvimentos deverão ser apresentados com a maior antecedência possível ao DWG, de acordo com o procedimento do mesmo, cabendo a este a decisão relativa ao nível de governo a atribuir à Base de Dados

4.1.3 *Designação de BDs*

A designação da BD seguirá a nomenclatura `business_<app description>` e é responsabilidade do WKG a aprovação para criação da mesma, no âmbito da sua atividade.

4.1.4 Documentação

O modelo de dados deve estar documentado no formato standard do banco, devendo as tabelas e campos ter uma descrição funcional perceptível para qualquer potencial consumidor bem como as suas relações. Deve também contemplar a rastreabilidade para as fontes dos dados.

A documentação deverá ficar guardada em local acessível para quem necessite de aceder ao mesmo.

4.1.5 Considerações sobre Modelo de Dados

A componente de ETL, deve ser assegurada pela ETL Tool. Caso não seja possível, devem ser apresentados os factos e argumentos para utilização de solução alternativa.

Não pode existir cópia de tabelas (que não sofram qualquer transformação) de curated para business, de forma a evitar redundância de dados.

No momento da criação das tabelas, deve ser sempre criado o descritivo relativo a cada campo assim como uma descrição da funcionalidade da tabela. Esta informação deverá ser mantida ao longo do ciclo de vida de cada tabela.

O idioma do modelo de dados a ser utilizado deve ser a definida pelos requisitos do projeto, sendo recomendado o inglês para novas iniciativas.

4.1.6 Designação de Tabelas

O nome das tabelas deverá seguir a nomenclatura <app>_<table type>_<description>, em que:

- <app> corresponde ao acrónimo da aplicação de 6 caracteres de acordo com o catálogo aplicacional do banco.
- <table type> corresponderá ao abaixo dependendo do tipo de modelação definido:
 - OUT: tabelas de output e.g. output table for model consumption, output table for data exploration
 - AGGR: tabelas de dados agregados para otimizar a visualização de dados – pex. PowerBI
 - VIEW: views
 - ABT: Analytical Base Table for analytical models

- AUX: tabelas auxiliares criadas no processo para exploração do utilizador final
- PARAM: tabelas de parametrização funcional – pex. carregadas pelo utilizador
- REF: Tabela de referência – tabelas com informação de referência transversal ao datalake (apenas na common zone)
- <description> deverá conter uma descrição abreviada da tabela explicitando o conteúdo da mesma.

A designação e criação de tabelas devem observar as seguintes regras:

- O número máximo total para a designação das tabelas é de 32 caracteres;
- Apenas podem ser utilizadas minúsculas;
- Apenas podem ser utilizados caracteres válidos (ASCII);
- As tabelas deverão ser particionadas por “data_date_part”. Pode existir situações em que os dados se referem a uma data de referência distinta da data de partição, devendo usar-se “ref_date”;
- No carregamento de tabelas o ETL tem de indicar nominalmente as colunas que utiliza (não usar select *);
- Tabelas auxiliares ao processo, temporárias e que não necessitam de ser exploradas pelos utilizadores, devem ficar na zona de Operations associada à business em questão.

4.1.7 Designação de campos

Relativamente às nomenclaturas para os campos das tabelas deverão ser observadas as seguintes regras:

- Número máximo de 32 caracteres;
- Snake_case (tudo em minúsculas e com os espaços substituídos por underscore);
- Preferencialmente evitar abreviaturas;
- Apenas podem ser utilizadas minúsculas;
- Apenas podem ser utilizados caracteres válidos (ASCII).

4.2 Operations

Conforme indicado no capítulo anterior, é nesta zona que devem ser criadas tabelas auxiliares aos processos:

- Tabelas temporárias que apenas servirão de suporte à própria aplicação, não sendo possível a exploração destes dados pelos utilizadores;
- Parametrizações técnicas da aplicação, que não necessitem de ser visíveis e/ou consumidas pelos utilizadores de negócio deverão também ficar nesta zona em oposição às parametrizações funcionais que deverão ficar refletidas na zona business;
- Logs técnicos da aplicação.

Estão tipicamente associadas a uma outra zona business ou common. Em casos específicos pode também ser associada a alguma raw ou curated.

4.2.1 Designação de Bases de Dados:

A nomenclatura a seguir para a criação de BDs de suporte a aplicações business deverá operations_<datazone>_<app_description> em que a datazone e a app_description serão iguais à designação da BD que lhe está associada.

4.2.2 Designação de Tabelas:

Para tabelas em zona operations é recomendado que seja seguida a nomenclatura <app>_<table type>_<description> em que:

- <app> acrónimo de 6 bytes da aplicação em APM referente à business
- <table type>:
 - TEMP: Tabela Temporária - tabelas temporárias criadas no processo, que não podem estar disponíveis para o utilizador final.
 - LOG: Tabela de Log - tabelas que contêm telemetria de aplicação, que não podem estar disponíveis para o utilizador final
 - CONF: tabelas de configuração - tabelas de configuração de aplicativos, que não podem estar disponíveis para o usuário final
- <description> deverá conter uma descrição abreviada da tabela explicitando o conteúdo da mesma.

4.3 Workbenches

Os workbenches tratam-se de zonas para exploração de dados e experimentação por parte dos utilizadores de negócio.

4.3.1 Designação de Bases de Dados:

A nomenclatura a seguir para a criação de Workbenches será: `workbench_<group/project>` em que `<group/project>` deverá ser referente a uma área de negócio, equipa ou projeto.

No caso de ser um `workbench` para um projeto, a Base de Dados terá de ser criada com uma data-fim específica, alinhado com o plano do mesmo.

4.3.2 Fontes de Dados e Utilização:

Não deverá haver utilização/consumo de dados de `workbenches` para `workloads` produtivos.

Podem utilizar informação das diferentes `datazones` desde que tenham os respetivos acessos ou outras fontes a que o próprio utilizador tenha acesso.

4.3.3 Considerações adicionais:

Os `workbenches` deverão seguir um modelo de governo específico que terá em consideração imputação de custos, espaço de processamento e armazenamento, housekeeping, etc.

5 EGRESS DE DADOS

O processo de extração de informação de Datalake Cloud tem de ser exclusivamente feito utilizando a Egress Tool.

6 CONSIDERAÇÕES FINAIS

Quaisquer questões relativamente ao entendimento das orientações dadas no documento deverão ser remetidas para as áreas de CDO-Data Architecture e CTO-Data Architecture.